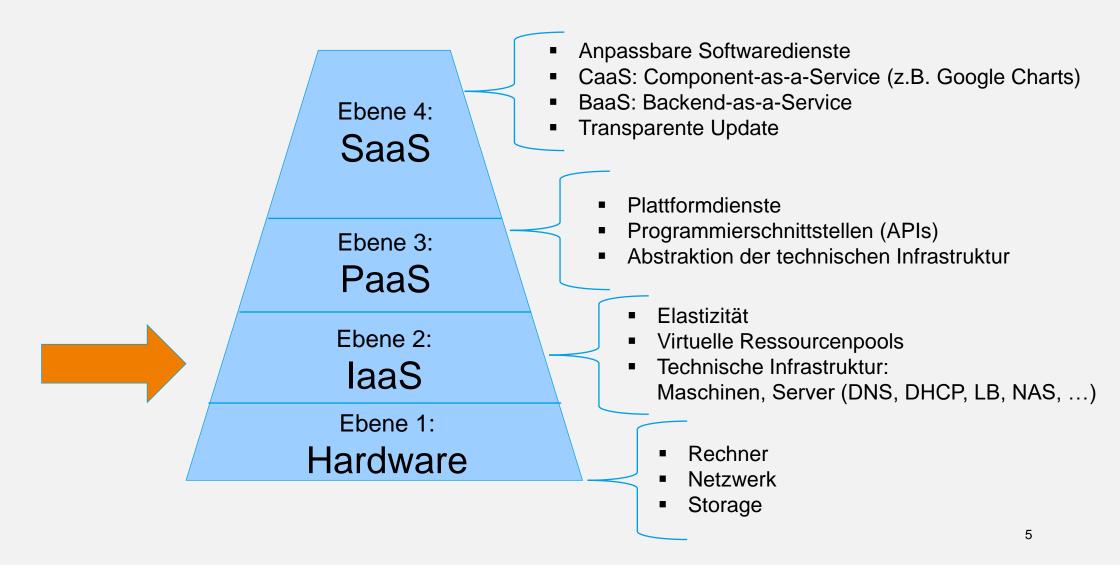


Infrastructure as a Service

Das Schichtenmodell des Cloud Computing: Vom Blech zur Anwendung.



Time2System im letzten Jahrhundert: > 1 Jahr.



http://de.wikipedia.org/wiki/Gro%C3%9Frechner

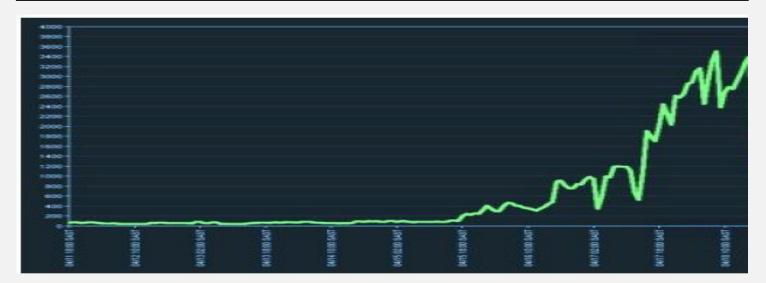
Time2System in der Cloud-Ära: In Echtzeit.

Slashdot-Effekt

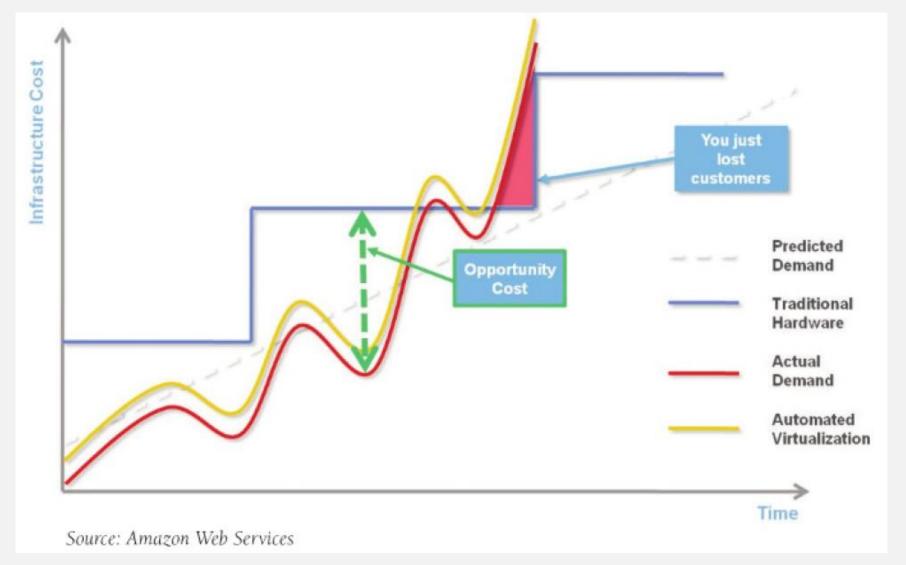
Der sogenannte **Slashdot-Effekt** oder das **Slashdotting** tritt auf, wenn eine bisher wenig populäre Website von einem IT-Online-Magazin wie Slashdot oder heise aufgegriffen wird und so binnen Minuten ein erheblicher Benutzeransturm auf die Website beginnt. Dieser führt oft dazu, dass erheblicher Traffic verursacht wird und der Server vorübergehend einzelne Anfragen nicht mehr oder nur noch sehr langsam beantworten kann. Die Seite ist dann "geslashdottet" (engl. *slashdotted*).

Große Websites, die von einer Server-Farm bedient werden, haben meistens keine Probleme mit dem erhöhten Traffic. Es sind vor allem kleinere Einzel-Server, die einem Slashdot-Effekt zum Opfer fallen. Manchmal wird der Slashdot-Effekt scherzhaft mit einem Distributed-Denial-of-Service-Angriff verglichen.

Um den Ansturm auf die betroffenen Seiten zu reduzieren, werden von unabhängigen Seiten immer wieder Mirrors angeboten in der Hoffnung, dass die Leser auf die Mirrors anstelle der Originalseite zugreifen. Koordiniert werden solche Projekte von Coral und MirrorDot.



Klassische Betriebsszenarien werden bei dynamischer Nachfrage teuer. Hohe Opportunitätskosten.



Definition laaS

Unter *laaS* versteht man ein Geschäftsmodell, das entgegen dem klassischen Kaufen von Rechnerinfrastruktur vorsieht, diese je nach Bedarf anzumieten und freizugeben.

Eigenschaften einer IaaS-Cloud:

- **Ressourcen-Pools**: Verfügbarkeit von scheinbar unbegrenzten Ressourcen, die Anfragen verteilt verarbeiten.
- Elastizität: Dynamische Zuweisung von zusätzlichen Ressourcen bei Bedarf.
- Pay-as-you-go Modell: Abgerechnet werden nur verbrauchte Ressourcen.

Ressourcen-Typen in einer laaS-Cloud:

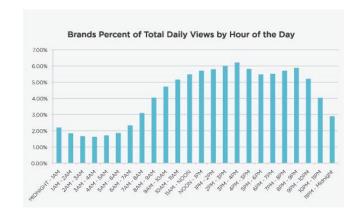
- **Rechenleistung**: Rechner-Knoten mit CPU, RAM und HD-Speicher.
- **Speicher**: Storage-Kapazitäten als Dateisystem-Mounts oder Datenbanken.
- Netzwerk: Netzwerk und Netzwerk-Dienste wie DNS, DHCP, VPN, CDN und Load Balancer.

Infrastruktur-Dienste einer JaaS-Cloud:

- Monitoring
- Ressourcen-Management

Skalierbarkeit: Effekte

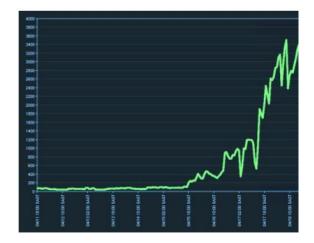
Tageszeitliche und saisonale Effekte: Mittags-Peak, Prime-Time-Peak, Wochenend-Peak, Weihnachten, Valentinstag, Muttertag, ...
(vorhersehbare Belastungsspitzen)



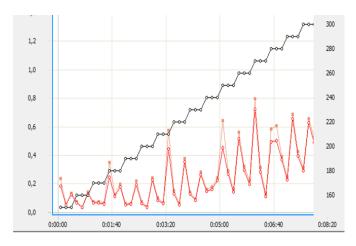
Kontinuierliches Wachstum



Sondereffekte: z.B. Slashdot-Effekt (unvorhersehbare Belastungsspitzen)



Temporäre Plattformen: Projekte, Tests, ...



Elastizitätsarten

Nachfrageelastizität: Die allokierten Ressourcen steigen / sinken mit der Nachfrage.

- Pseudo-Elastizität: Schneller Aufbau. Kurze Kündigungsfrist.
- Echtzeit-Elastizität: Allokation und Freigabe von Ressourcen innerhalb von Sekunden. Automatisierter Prozess mit manuellen Triggern oder nach Zeitplan.
- Selbstadaptive Elastizität: Automatische Allokation und Freigabe von Ressourcen in Echtzeit auf Basis von Regeln und Metriken.

Angebotselastizität: Die allokierten Ressourcen steigen / sinken mit dem Angebot.

- Dies ist das typische Verhalten eines Grids: Alle verfügbaren Rechner werden allokiert.
- Es sind auch Varianten verfügbar, bei denen man für freie Ressourcen bieten kann.

Einkommenselastizität: Die allokierten Ressourcen steigen / sinken mit dem Einkommen bzw. dem Budget.

Es gibt vielerlei Anbieter für Public und Private laaS Clouds.

Public IaaS Cloud

packet.net

DigitalOcean

Google Compute Engine

Amazon EC2

Microsoft Azure

RackSpace

ProfitBricks

Private Open Source laaS Cloud

OpenStack

CloudStack

vCloud

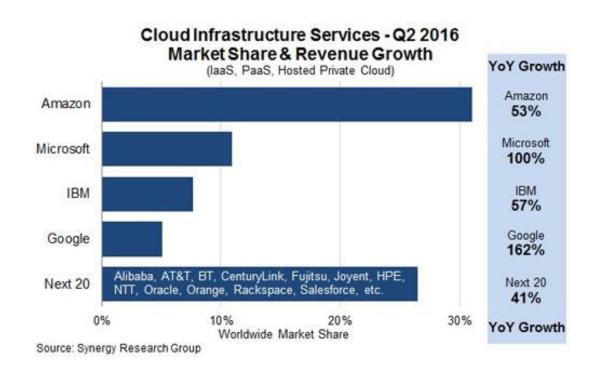
HPE Helion Eucalyptus

OpenNebula

Nimbus

Der momentane laaS Markt.





2016 Magic Quadrant for Cloud Infrastructure as a Service, Worldwide, Gartner https://aws.amazon.com/de/resources/gartner-2015-mq-learn-more

Es gibt eine Reihe an gängigen Kriterien bei der Auswahl einer passenden laaS-Cloud.

- Unterstützte Cloud-Varianten (Private Cloud, Public Cloud, Hybrid Cloud, ...)
- Zuverlässigkeit / Verfügbarkeit
- Sicherheit und Datenschutz
- Vorhersagbare und stabile Performance
- Preismodell: Fixe und flexible Kosten
- Skalierbarkeit: Grenzen, Automatismen und Reaktionszeiten
- Lock-In der Daten und Anwendungen: Offene APIs
- Haftung
- Support

Ein Service Level Agreement (SLA) ist ein Vertrag mit Zuverlässigkeitszusagen für Ressourcen und Dienste.

Verfügbarkeitsklassen:

Availability %	Downtime per Year	Downtime per Month	Downtime per Week
99.9% (three nines)	8.76 hours	43.2 minutes	10.1 minutes
99.95%	4.38 hours	21.56 minutes	5.04 minutes
99.99% (four nines)	52.6 minutes	4.32 minutes	1.01 minutes
99.999% (five nines)	5.26 minutes	25.9 seconds	6.05 seconds
99.9999% (six nines)	31.5 seconds	2.59 seconds	.0605 seconds

Beispiel: Amazon S3 (Storage)

Service Commitment

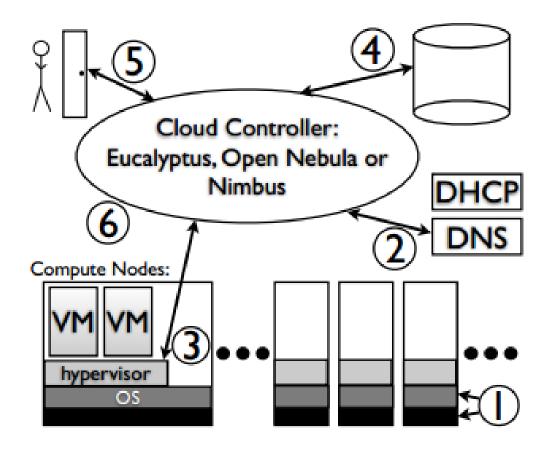
AWS will use commercially reasonable efforts to make Amazon S3 available with a Monthly Uptime Percentage (defined below) of at least 99.9% during any monthly billing cycle (the "Service Commitment"). In the event Amazon S3 does not meet the Service Commitment, you will be eligible to receive a Service Credit as described below.

Monthly Uptime Percentage	Service Credit Percentage	
Equal to or greater than 99% but less than 99.9%	10%	
less than 99%	25%	



Architektur einer laaS-Cloud

Eine laaS-Referenzarchitektur.



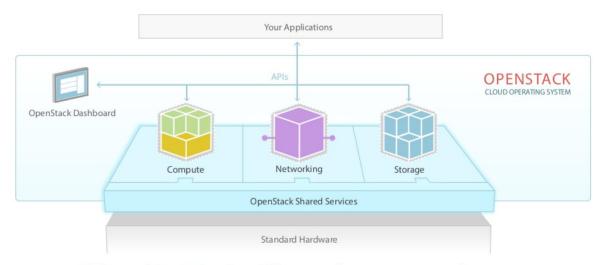
- 1. Hardware und Betriebssystem
- 2. Virtuelles Netzwerk und Netzwerkdienste
- 3. Virtualisierung
- 4. Datenspeicher und Image-Verwaltung
- Managementschnittstelle für Administratoren und Benutzer
- Cloud Controller für das mandantenspezifische
 Management der Cloud-Ressourcen



laaS mit OpenStack

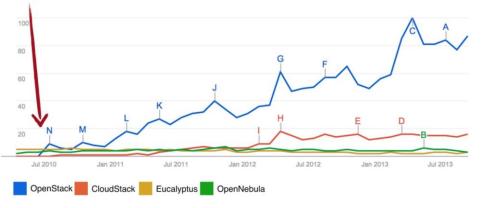
OpenStack: Der de-facto Standard für Open-Source Private IaaS Clouds.

- Open Source Projekt wurde maßgeblich initiiert von RackSpace und der NASA.
- Das erste vollständige Release erfolgte im Oktober 2010.
- Lizenziert unter der Apache Lizenz.
- Eine Vielzahl der klassischen IT-Player (SAP, IBM, vmWare, HP, Oracle, Cisco) sind Teil der OpenStack-Community.
- Sehr aktives Open-Source-Projekt mit > 400 aktiven Committern.
- Ausgelegt eher als Framework denn als fertiges System für IaaS-Clouds.



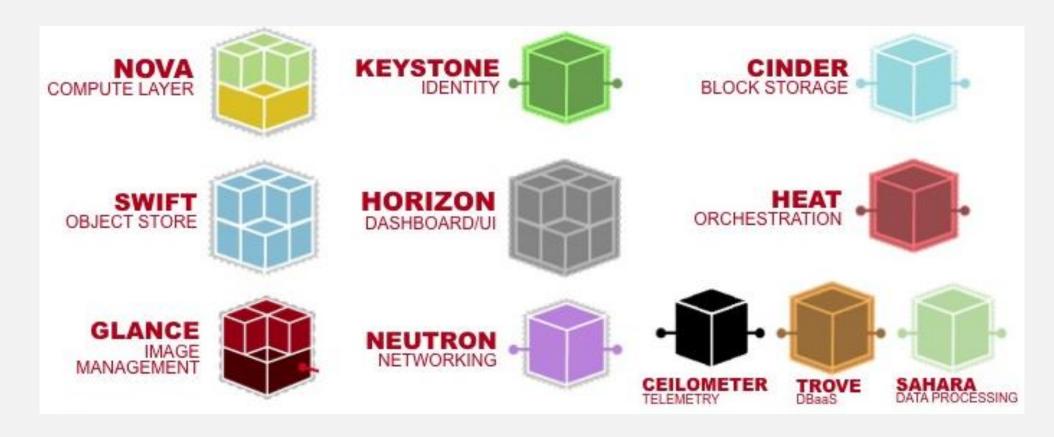
The Battle is Over (open src)

OpenStack Launch



Quellen: http://de.slideshare.net/randybias/state-of-the-stack282

Die OpenStack Komponenten.



Quelle: http://de.slideshare.net/sgordon2/deep-dive-openstack-summit-red-hat-summit-2014

MicroStack



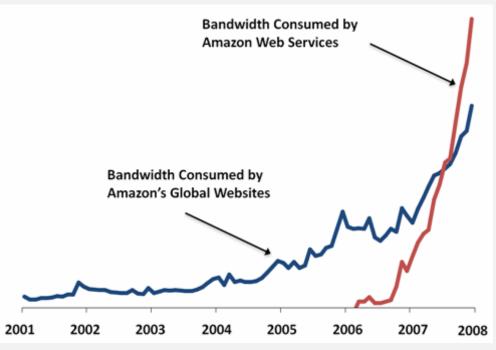
- OpenStack lokal, zum Ausprobieren und für die Entwicklung
 - https://microstack/run/
 - https://ubuntu.com/openstack/install
- Zwei Befehle:
 \$ sudo snap install microstack --edge --devmode
 \$ sudo microstack.init --auto
- Video dazu: https://www.openstack.org/videos/summits/virtual/OpenStack-on-rails-meet-MicroStack



laaS mit Amazon EC2

Die Amazon EC2 laaS Cloud.

- Amazon bietet im Rahmen der AWS (Amazon Web Service) auch eine JaaS-Cloud an.
- Historie:
 - Start innerhalb von Amazon im Jahr 2001
 - Öffentliche Beta ab 25. August 2006
 - Ab Mitte 2007 mehr Bandbreite durch Dritte in der Cloud konsumiert, als durch die Amazon Webseiten
 - Produktionsreife ab 23. Oktober 2008
 - 2005 bis 2012 ca. 12 Mrd. \$ Investment in die Infrastruktur
 - 2015: 1,5 bis 2 Mio. Server in 10 globalen Rechenzentren.
- On-Demand-, Reserved- und Spot-Instanzen in verschiedenen Größen: (http://aws.amazon.com/de/ec2/instance-types) sowie diverse Storage- und Netzwerkdienste.



http://aws.typepad.com/aws/2008/05/lots-of-bits.html

Neben der Amazon EC2 laaS Cloud bietet Amazon noch viele weitere laaS-Komponenten, PaaS- und SaaS-Dienste.



Compute

EC2

EC2 Container Service

Lightsail

Elastic Beanstalk

Lambda Batch



Storage

S3

EFS

Glacier

Storage Gateway



Database

RDS

DynamoDB

ElastiCache

Amazon Redshift



Networking & Content Delivery

VPC

CloudFront

Direct Connect

Route 53



Developer Tools

CodeStar

CodeCommit

CodeBuild

CodeDeploy

CodePipeline

X-Ray



Management Tools

CloudWatch

CloudFormation

CloudTrail

Config

OpsWorks

Service Catalog

Trusted Advisor

Managed Services



Security, Identity & Compliance

IAM

Inspector

Certificate Manager

Directory Service

WAF & Shield

Artifact

Amazon Macie

CloudHSM



Analytics

Athena

EMR

CloudSearch

Elasticsearch Service

Kinesis

Data Pipeline

QuickSight

AWS Glue



Artificial Intelligence

Lex

Amazon Polly

Rekognition

Machine Learning



Internet Of Things

AWS IOT

AWS Greengrass



Contact Center

Amazon Connect



Game Development

Amazon GameLift



Application Services

Step Functions

SWF

API Gateway

Elastic Transcoder



Messaging

Simple Queue Service

Simple Notification Service

Simple Email Service

Business Productivity

WorkDocs

WorkMail

Amazon Chime



Desktop & App Streaming

WorkSpaces

AppStream 2.0



Mobile Services

Mobile Hub

Cognito

Device Farm

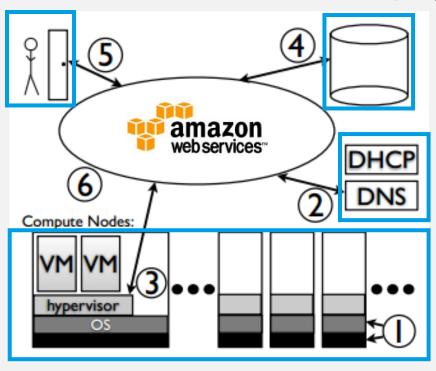
Mobile Analytics

28

Architektur der Amazon EC2.

- AWS Management
- Console
- Webservice-API

- EBS (Elastic Block Store)
- S3 (Simple Storage Service)



- DNS / DHCP
- Elastic IPs
- VPC (Virtual Private Cloud)
- Elastic Load Balancer
- CloudFront CDN

- EC2-Knoten mit Xen- und HVM-Virtualisierung
- Monitoring über CloudWatch
- AutoScaling auf Basis von CloudWatch-Metriken

Die globale Verteilung der Amazon EC2.



Region und Anzahl der Availability Zones

USA Ost China Nord-Virginia (6),

Peking (2)

Ohio (3)

Europa

USA West Nordkalifornien (3), Frankfurt (3), Irland (3), London (2)

Oregon (3)

Südamerika

Asien-Pazifik

São Paulo (3)

Mumbai (2), Seoul (2), Singapur (2),

AWS GovCloud (US-

West) (2) Sydney (3), Tokio (3)

Kanada

Zentral (2)



Neue Region (in Kürze verfügbar)

Bahrain

China

Frankreich

Hongkong

Schweden

AWS GovCloud (US-

East)



Sicherheitsaspekte der Amazon EC2.



- Zertifiziert nach ISO 27001 (Empfehlung BSI). Im deutschen und irischen Datencenter den EU-Datenschutzrichtlinien unterworfen.
 Amazon ist ebenso global dem US Patriot Act unterworfen.
- Daten und Instanzen können global auf alle Rechenzentren verteilt werden. Jedes dieser Rechenzentren besteht aus mehreren Verfügbarkeitszonen, die ein in sich geschlossenes Rechen-Cluster darstellen.
- Jede EC2-Instanz muss einer Security Group zugeordnet sein. Eine Security Group ist die Konfiguration der Inbound-Firewall für Instanzen.
- Der Zugriff auf die EC2-Administrationsfunktionen kann über das zentrale IAM-System gesteuert werden. Es können Benutzer angelegt, autorisiert und authentifiziert werden. Für den Zugriff per API können Zugriffsschlüssel und Zertifikate vergeben und widerrufen werden. Eine Multi-Faktor-Authentifizierung wird unterstützt.
- Zugriff auf Linux-Instanzen per SSH. Authentifzierung an der Instanz über SSH-Zertifikat (Keypair) und Benutzername ("root"/"ec2-user"/"ubuntu").
- Zugriff auf Windows-Instanzen per Remote Desktop. Das Admin-Passwort für die Maschine kann per Weboberfläche / API abgefragt werden.

Über die AWS Management Console können alle Dienste der Amazon-Cloud gesteuert werden.

